

Lec-19. 数理统计介绍、随机样本、统计量

主讲教师：吴利苏 (wulisu@sdust.edu.cn)

主页：wulisu.cn

本章内容

1. 数理统计部分介绍
2. 统计量与常用统计量
3. 三个重要抽样分布

数理统计

- 数理统计是以概率论为基础，根据试验或观察数据，来研究随机现象，对研究对象的客观规律做出合理的估计和判断.

数理统计

- 数理统计是以概率论为基础，根据试验或观察数据，来研究随机现象，对研究对象的客观规律做出合理的估计和判断.
- 数理统计主要内容：

数理统计

- 数理统计是以概率论为基础，根据试验或观察数据，来研究随机现象，对研究对象的客观规律做出合理的估计和判断.
- 数理统计主要内容：
 - 数据收集（获取、预处理、数据清洗）；

数理统计

- 数理统计是以概率论为基础，根据试验或观察数据，来研究随机现象，对研究对象的客观规律做出合理的估计和判断.
- 数理统计主要内容：
 - 数据收集（获取、预处理、数据清洗）；
 - 数据处理（聚类分析、特征分析、降维分析、主成分分析、特征提取）；

数理统计

- 数理统计是以概率论为基础，根据试验或观察数据，来研究随机现象，对研究对象的客观规律做出合理的估计和判断.
- 数理统计主要内容：
 - 数据收集（获取、预处理、数据清洗）；
 - 数据处理（聚类分析、特征分析、降维分析、主成分分析、特征提取）；
 - 结果分析（统计推断）.

概率论和数理统计

- 在概率论中，已知随机变量的分布的前提下，研究它的性质、特点和规律性。例如，求数字特征、求随机变量函数的分布等等。
- 在数理统计中，随机变量的分布未知或者部分未知，通过数据对随机变量作出推断。

数理统计学习内容

Chap-6 总体、随机样本、统计量、常用的统计量和抽样分布

- χ^2 分布、 t 分布、 F 分布.

Chap-7 估计问题

- 点估计：分布函数已知，参数未知，估计未知参数.
 - ★ 矩估计、极大似然估计.
- 区间估计：对参数处在某个区间的可信程度的估计.

Chap-8 假设检验问题

- 分布函数未知，或分布函数只知道形式而参数未知，提出某些假设，进行检验推断.

总体和个体

- 总体 试验的全部可能的观察值;
- 个体 总体中的每个可能观察值;
- 总体的容量 总体中所包含的个体数;
- 有限总体 容量有限的总体;
- 无限总体 容量无限的总体, 通常将容量非常大的有限总体也按无限总体处理.

例

- 研究 2000 名学生的年龄, 这些学生的年龄的全体构成一个总体, 每个学生的年龄就是个体.
- 考察一湖泊中某种鱼的含汞量, 所得总体是有限总体.
- 考察全国正在使用的某种型号灯泡的寿命所形成的总体. 由于可能观察值的个数很多, 可认为是无限总体.
- 一城市空气质量, $PM_{2.5}$ 值, 无限总体.

总体分布

- 实际中人们通常只关注总体的某个（或几个）指标.
- 总体的某个指标 X , 对于不同的个体来说有不同的取值, 这些取值构成一个分布, 因此 X 可以看成是一个随机变量.
- 有时候直接将 X 称为总体. 假设 X 的分布函数为 $F(x)$, 也称总体 X 具有分布 $F(x)$.

如何推断总体分布的未知参数（或分布）？

在实际中，总体的分布未知，或总体的分布已知，但某些参数未知，要对总体进行推断，我们研究所有个体是不可能的，故须抽出部分个体进行研究。

- **样本** 从总体中抽出的部分个体.
- **样本容量** 样本中所含个体的个数..

- 简单随机样本 满足以下两个条件的随机样本 (X_1, \dots, X_n) 称为容量是 n 的简单随机样本.
 - 代表性: 每个 X_i 与 X 同分布;
 - 独立性: X_1, \dots, X_n 是相互独立的随机变量.
- 样本值 X_1, \dots, X_n 的观察值 x_1, \dots, x_n .

[注]: 后面提到的样本均指简单随机样本。

简单随机抽样

- 获得简单随机样本的抽样称为简单随机抽样.

如何进行简单随机抽样?

- 对于有限总体, 采用放回抽样.
- 但当总体容量很大的时候, 放回抽样有时候很不方便, 因此在实际中当总体容量比较大时, 通常将不放回抽样所得到的样本近似当作简单随机样本来处理.
- 对于无限总体, 一般采取不放回抽样.

由样本定义得, 若 X_1, \dots, X_n 是 F 的样本, 则 X_1, \dots, X_n 的联合分布函数

$$F^*(X_1, \dots, X_n) = \prod F(x_i).$$

又若 X 具有概率密度 f , 则 X_1, \dots, X_n 的联合概率密度为

$$f^*(x_1, \dots, x_n) = \prod f(x_i).$$

例

设一批灯泡的寿命 X (小时) 服从参数为 θ 的指数分布, θ 未知. 从该批灯泡中采用简单随机抽样抽取容量为 10 的样本 X_1, \dots, X_{10} . 对样本实施观测, 得到样本值为

6394	1105	4717	1399	7952
17424	3275	21639	2360	2896

写出样本的概率密度.

解：总体 $X \sim \text{Exp}(\theta)$, X_1, \dots, X_{10} 为来自总体 X 的一个样本, 则 (X_1, \dots, X_{10}) 的联合概率密度为

$$\begin{aligned} f^*(x_1, \dots, x_{10}) &= \prod_{i=1}^{10} f(x_i) \\ &= \begin{cases} \frac{1}{\theta^{10}} e^{-\frac{1}{\theta} \sum_{i=1}^{10} x_i} & x_1 > 0, \dots, x_n > 0; \\ 0 & \text{其他.} \end{cases} \end{aligned}$$

□

- 如何由已知样本值来估计未知参数 θ ?

为了估计指数分布的参数 θ , 进行抽样观测, 得到样本 X_1, \dots, X_{10} 和样本值

6394	1105	4717	1399	7952
17424	3275	21639	2360	2896

样本中包含了许多信息。

对于推断总体的参数或分布而言, 有些是有用的、重要的信息, 有些则并不重要。

上例的样本至少提供了两种信息:

- 1) 10 个灯泡的平均寿命; -有用且重要的信息
- 2) 灯泡寿命的序号 (如 6394 是第 1 个). -不重要信息

构造统计量

从样本中提取有用的信息来研究总体的分布及各种特征数.-构造统计量.

- **统计量** 设 X_1, \dots, X_n 是来自总体 X 的一个样本, $g(X_1, \dots, X_n)$ 是 X_1, \dots, X_n 的函数, 若 g 中不含未知数, 则称 $g(X_1, \dots, X_n)$ 是一个统计量.

注: X_1, \dots, X_n 是随机变量, 而统计量 $g(X_1, \dots, X_n)$ 是随机变量的一个函数. 设 x_1, \dots, x_n 是相应于样本 X_1, \dots, X_n 的一个样本值, 则称 $g(x_1, \dots, x_n)$ 是 $g(X_1, \dots, X_n)$ 的观察值.

例

设 X_1, X_2, X_3 是来自总体 $N(\mu, \sigma^2)$ 的一个总体, 其中 μ 已知, σ^2 未知, 判断下列各式哪些是统计量.

$$T_1 = X_1,$$

$$T_2 = X_1 + X_2 e^{X_3}$$

$$T_3 = \frac{1}{3}(X_1 + X_2 + X_3), \quad T_4 = \max\{X_1, X_2, X_3\}$$

$$T_5 = X_1 + X_2 - 2\mu, \quad T_6 = \frac{1}{\sigma^2}(X_1^2 + X_2^2 + X_3^2)$$

常用的统计量

设 X_1, \dots, X_n 是来自总体的一个样本,.

- 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$;
- 样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right);$$

样本标准差

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

常用的统计量

- 样本 k 阶原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, k = 1, 2, \dots;$
- 样本 k 阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k.$

注: B_2 与 S^2 不一样. 样本方差 S^2 中, 除 n 会低估方差, 为保证无偏性, 修正除 $\frac{1}{n-1}$ (Chap7-3) .

当总体数字特征未知时

- 用样本均值 \bar{X} 估计总体均值 $\mu = E(X)$;
- 用样本方差 S^2 估计总体方差
 $\sigma^2 = E(X - \mu)^2$;
- 用样本原点矩 A_k 估计总体原点矩
 $\mu_k = E(X^k)$;
- 用样本中心矩 B_k 估计总体中心矩
 $\nu_k = E(X - \mu)^k$.

这些非常直观的想法，有什么理论依据吗？
这部分内容我们会在 Chap7 中介绍。

性质

若总体 X 的 k 阶矩 $E(X^k) = \mu_k$ 存在, 则当 $n \rightarrow \infty$ 时, 有 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k$.

性质

若总体 X 的 k 阶矩 $E(X^k) = \mu_k$ 存在, 则当 $n \rightarrow \infty$ 时, 有 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k$.

证明: 由于 X_1, \dots, X_n 独立且同 X 同分布,

$$E(X_1^k) = E(X_2^k) = \dots = E(X_n^k) = \mu_k,$$

由辛钦大数定律知, $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k$. □

进一步由依概率收敛的性质知

$$g(A_1, \dots, A_k) \xrightarrow{P} g(\mu_1, \dots, \mu_k),$$

其中 g 是连续函数. 下一章矩估计的理论依据.

经验分布函数

定义

设 x_1, \dots, x_n 是来自分布函数 $F(x)$ 的总体 X 的样本观察值. X 的**经验分布函数** $F_n(x)$ 定义为

$$F_n(x) = \frac{\sharp(x_i \leq x)}{n}, \quad -\infty < x < +\infty$$

其中 $\sharp(x_i \leq x)$ 表示 x_1, \dots, x_n 中小于或等于 x 的个数.

注: 由定义, 当给定样本观察值 x_1, \dots, x_n 时,
 $F_n(x)$ 是 X 的函数, 具有分布函数的三个条件:

1. $F_n(x)$ 是 x 的不减函数.
2. $0 \leq F_n(x) \leq 1$, $F(-\infty) = 0$, $F(+\infty) = 1$.
3. $F_n(x)$ 是一个右连续函数.

故 $F_n(x)$ 是一个分布函数. 当 x_1, \dots, x_n 各不同时, $F_n(x)$ 是以等概率 $\frac{1}{n}$ 取 x_1, \dots, x_n 的离散型随机变量的分布函数.

一般地, 设 x_1, \dots, x_n 是总体 X 的容量为 n 的样本观察值, 先将 x_1, \dots, x_n 按自小到大的次序排序, 重新编号为 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$, 则

$$F_n(x) = \begin{cases} 0 & x < x_{(1)}; \\ \frac{k}{n} & x_{(k)} \leq x < x_{(k+1)} \quad k = 1, 2, \dots, n-1; \\ 1 & x \geq x_{(n)}. \end{cases}$$

例

设 X 有样本观察值 $-1, 1, 2$, 则

$$F_3(x) = \begin{cases} 0 & x < -1; \\ \frac{1}{3} & -1 \leq x < 1; \\ \frac{2}{3} & 1 \leq x < 2; \\ 1 & x \geq 2. \end{cases}$$

当给定 x 时, $F_n(x)$ 是样本 X_1, \dots, X_n 的函数, 故它是一个统计量.

定理 (格里汶科定理)

设 X_1, \dots, X_n 是来自以 $F(x)$ 为分布函数的总体 X 的样本, $F_n(x)$ 是经验分布函数, 则有

$$P \left\{ \lim_{n \rightarrow \infty} \sup_{-\infty < x < \infty} |F_n(x) - F(x)| = 0 \right\} = 1.$$

上面定理表明 $F_n(x)$ 在整个实数轴上以概率 1 均匀收敛于 $F(x)$. 所以, 当 n 很大时, $F_n(x)$ 可以很好地近似总体分布函数 $F(x)$. 这是以样本推断总体的依据.

抽样分布

- 统计量的分布被称为**抽样分布**.
- 当总体 X 服从一般分布 (如指数分布、均匀分布等), 要得出统计量的分布是很困难的.
- 当总体 X 服从正态分布时, 统计量 \bar{X}, S^2 是可以计算的, 那么服从什么分布呢?
- 下面将介绍数理统计中三个重要的抽样分布— χ^2 分布, t 分布, F 分布.

1. χ^2 分布

定义

设 X_1, \dots, X_n 是来自总体 $N(0, 1)$ 的样本, 则称统计量

$$\chi^2 = X_1^2 + \dots + X_n^2$$

为服从自由度为 n 的 χ^2 分布, 记为 $\chi^2 \sim \chi^2(n)$.

自由度指右端包含独立变量的个数.

$\chi^2(n)$ 的概率密度和图像

$\chi^2(n)$ 的概率密度为

$$f(y) = \begin{cases} \frac{1}{2^{n/2}\Gamma(n/2)} y^{\frac{n}{2}-1} e^{-\frac{y}{2}} & y > 0; \\ 0 & \text{其他.} \end{cases}.$$

其中 $\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx$.

$f(y)$ 的图像.

χ^2 分布和 Γ 分布

$\chi^2(n)$ 的概率密度为

$$f(y) = \begin{cases} \frac{1}{2^{n/2}\Gamma(n/2)} y^{\frac{n}{2}-1} e^{-\frac{y}{2}} & y > 0; \\ 0 & \text{其他.} \end{cases}$$

$\Gamma(\alpha, \theta)$ ($\alpha > 0, \theta > 0$) 的概率密度为

$$f(x) = \begin{cases} \frac{1}{\theta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-\frac{x}{\theta}} & x > 0; \\ 0 & \text{其他.} \end{cases}$$

性质

- $\chi^2(1) \sim \Gamma(\frac{1}{2}, 2);$
- $\chi^2(n) \sim \Gamma(\frac{n}{2}, 2).$

证明: $X_i \sim N(0, 1)$, 所以

$$X_i^2 \sim \chi^2(1) \sim \Gamma(\frac{1}{2}, 2),$$

X_i^2 相互独立, 由 Γ 分布的可加性,

$$\chi^2 = \sum_{i=1}^n X_i^2 \sim \Gamma(\frac{n}{2}, 2).$$

χ^2 分布的性质

性质 (可加性)

设 $\chi_1^2 \sim \chi^2(n_1)$, $\chi_2^2 \sim \chi^2(n_2)$, 且 χ_1^2, χ_2^2 相互独立, 则

$$\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2).$$

- 一般地, 设 $\chi_i^2 \sim \chi^2(n_i)$, 且 $\chi_i^2 (i = 1, \dots, m)$ 相互独立, 则

$$\sum_{i=1}^m \chi_i^2 \sim \chi^2(n_1 + \dots + n_m).$$

χ^2 分布的性质

性质 (期望和方差)

若 $\chi^2 \sim \chi^2(n)$, 则有 $E(\chi^2) = n$, $D(\chi^2) = 2n$.

证: $X_i \sim N(0, 1)$, $E(X_i^2) = D(X_i) = 1$,
 $D(X_i^2) = E(X_i^4) - E(X_i^2)^2 = 3 - 1 = 2$.

则 $E(\chi^2) = E(\sum_{i=1}^n X_i^2) = \sum E(X_i^2) = n$.

$D(\chi^2) = D(\sum_{i=1}^n X_i^2) = \sum D(X_i^2) = 2n$. □

χ^2 分布的性质

性质 (上分位数)

给定 $0 < \alpha < 1$, 满足条件

$$P\{\chi^2 > \chi_{\alpha}^2(n)\} = \int_{\chi_{\alpha}^2(n)}^{\infty} f(y) dy = \alpha$$

的 $\chi_{\alpha}^2(n)$ 为 χ^2 分布的 **上 α 分位数**.

上下 α 分位数

$X, F(x), f(x),$

- 下 α 分位数

$$P\{X \leq \chi_{\underline{\alpha}}\} = F(\chi_{\underline{\alpha}}) = \int_{-\infty}^{\underline{\alpha}} f(x) dx = \alpha.$$

- 上 α 分位数

$$P\{X > \chi_{\alpha}\} = 1 - F(\chi_{\alpha}) = \int_{\chi_{\alpha}}^{+\infty} f(x) dx = \alpha.$$

- 查附录 5($n = 40$ 为止)

$$\alpha = 0.05, n = 20, \chi_{0.05}^2(20) = 31.410.$$

$$\alpha = 0.1, n = 25, \chi_{0.1}^2(25) = 34.382.$$

- 当 n 充分大时, 费希尔证明

$$\chi_{\alpha}^2 \approx \frac{1}{2}(z_{\alpha} + \sqrt{2n-1})^2.$$

其中 z_{α} 是标准正态分布上的上 α 分位数.

- 当 $n > 40$ 时, 可用上式求,

$$\chi_{0.05}^2(50) \approx \frac{1}{2}(1.645 + \sqrt{99})^2 = 67.221$$

例

设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 已知. (X_1, \dots, X_n) 是取自总体 X 的样本. 求统计量

$$\chi^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$$

的分布.

证明: 令 $Y_i = \frac{X_i - \mu}{\sigma}$, 则 $Y_i \sim N(0, 1)$.

因此 $\chi^2 = \sum (\frac{X_i - \mu}{\sigma})^2 = \sum Y_i^2 \sim \chi^2(n)$. □

2. t 分布

定义

设 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$, 且 X, Y 相互独立, 则称

$$t = \frac{X}{\sqrt{Y/n}}$$

为服从自由度为 n 的 t 分布, 记为 $t \sim t(n)$.

概率密度和图像

t 分布又称学生氏分布, 概率密度为

$$h(t) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{\pi n} \Gamma(\frac{n}{2})} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \quad -\infty < t < \infty.$$

图像.

性质

1. 关于 $t=0$ 对称.
2. 当 n 充分大时, 其图形类似于标准正态分布的概率密度图形.

事实上,

$$\lim_{n \rightarrow \infty} h(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}$$

当 n 充分大, t 分布近似 $N(0, 1)$, n 小, t 分布与 $N(0, 1)$ 相差很大.

性质

- t 分布的上分位数 对于给定的 α , 满足

$$P\{t > t_{\alpha}(n)\} = \int_{t_{\alpha}(n)}^{\infty} h(t) dt = \alpha$$

的 $t_{\alpha}(n)$ 是 $t(n)$ 分布的上 α 分位数.

- $t_{1-\alpha}(n) = -t_{\alpha}(n)$.
- 查表求 $t_{\alpha}(n)$. 当 $n > 45$ 时, $t_{\alpha}(n) \approx z_{\alpha}$.

例

设 $T \sim t(n)$, $t(n)$ 的上 α 分位数满足

$$P\{T > t_\alpha(n)\} = \int_{t_\alpha(n)}^{\infty} t(y; n) dy = \alpha,$$

求 $t_{0.05}(10)$, $t_{0.025}(15)$ 的值.

解: $t_{0.05}(10) = 1.8125$, $t_{0.025}(15) = 2.1315$. □

3. F 分布

定义

设 $U \sim \chi^2(n_1)$, $V \sim \chi^2(n_2)$ 且 U, V 相互独立, 则称

$$F = \frac{U/n_1}{V/n_2}$$

服从自由度为 (n_1, n_2) 的 F 分布, 记为 $F \sim F(n_1, n_2)$.

3. F 分布的概率密度和图像

概率密度

$$\phi(y) = \begin{cases} \frac{\Gamma(\frac{n_1+n_2}{2}) (\frac{n_1}{n_2})^{\frac{n_1}{2}} y^{\frac{n_1}{2}-1}}{\Gamma(\frac{n_1}{2}) \Gamma(\frac{n_2}{2}) (1+\frac{n_1 y}{n_2})^{\frac{n_1+n_2}{2}}} & y > 0; \\ 0 & \text{其他.} \end{cases}$$

图像.

3. F 分布的性质

- 若 $F \sim F(n_1, n_2)$, 则 $\frac{1}{F} \sim F(n_2, n_1)$.
- 上分位数 对于给定的 α , $0 < \alpha < 1$, 满足条件

$$P\{F > F_\alpha(n_1, n_2)\} = \int_{F_\alpha(n_1, n_2)}^{\infty} \phi(y) dy = \alpha$$

的 F_{n_1, n_2} 就是 $F(n_1, n_2)$ 分布的上 α 分位数.

- 查表 $F_{0.025}(8, 7) = 4.90$, $F_{0.05}(30, 14) = 2.31$.
- F 分布的上 α 分位数满足

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}. \quad (1)$$

- 利用上式，可以求分布表中未列出的常用的上 α 分位数.

例如： $F_{0.95}(12, 9) = 0.357$.

(1) 式的证明: $F \sim F(n_1, n_2)$

$$\begin{aligned} 1 - \alpha &= P\{F > F_{1-\alpha}(n_1, n_2)\} \\ &= P\left\{\frac{1}{F} < \frac{1}{F_{1-\alpha}(n_1, n_2)}\right\} \\ &= 1 - P\left\{\frac{1}{F} \geq \frac{1}{F_{1-\alpha}(n_1, n_2)}\right\} \\ &= 1 - P\left\{\frac{1}{F} > \frac{1}{F_{\alpha}(n_1, n_2)}\right\} \end{aligned}$$

$\frac{1}{F} \sim F(n_2, n_1)$, 则

$$P\left\{\frac{1}{F} > \frac{1}{F_{1-\alpha}(n_1, n_2)}\right\} = P\left\{\frac{1}{F} > F_{\alpha}(n_2, n_1)\right\} = \alpha,$$

故 $F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$.

例

X, Y, Z 相互独立, 服从 $N(0, 1)$, 则

(1) $X^2 + Y^2 + Z^2 \sim \chi^2(3),$

(2) $\frac{X}{\sqrt{(Y^2+Z^2)/2}} \sim t(2),$

(3) $\frac{2X^2}{Y^2+Z^2} \sim F(1, 2).$

若 $t \sim t(n)$, 则 $t^2 \sim F(1, n).$

4. 正态总体的样本均值与样本方差的分布

X 的 $E(X) = \mu$, $D(X) = \sigma^2$,

设 X_1, \dots, X_n 是来自总体 X 的样本, \bar{X}, S^2 分别是样本均值喝样本方差, 则有 $E(\bar{X}) = \mu$,

$$D(\bar{X}) = \frac{\sigma^2}{n}, \text{ 而 } E(S^2) = E\left(\frac{1}{n-1}(\sum X_i^2 - n\bar{X}^2)\right) = \frac{1}{n-1}(\sum E(X_i^2) - nE(\bar{X}^2)) = \frac{1}{n-1}(\sum(\sigma^2 + \mu^2) - n(\sigma^2/n + \mu^2)) = \sigma^2 = D(X).$$

$$\text{即 } E(S^2) = \sigma^2, D(S^2) = \frac{2\sigma^4}{n-1}.$$

设 $X \sim N(\mu, \sigma^2)$, 则 $\bar{X} = \frac{1}{n} \sum X_i \sim N(\mu, \frac{\sigma^2}{n})$

定理 2 设 X_1, \dots, X_n 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, \bar{X} 是样本均值, 则有 $\bar{X} \sim N(\mu, \sigma^2/n)$ 对于正态总体 $N(\mu, \sigma^2)$ 的样本均值 \bar{X} , 样本方差 S^2 有以下两个定理.

定理 3 设 X_1, \dots, X_n 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, 则 1. $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$. 2. \bar{X} 与 S^2 相互独立.

例. $\frac{\sum(X_i - \bar{X})^2}{\sigma^2} = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$, 有一个约束条件 $\sum(X_i - \bar{X}) = 0$.

$$\frac{\sum(X_i - \mu)^2}{\sigma^2} = \sum\left(\frac{X_i - \mu}{\sigma}\right)^2 \sim \chi^2(n).$$

定理 4 设 X_1, \dots, X_n 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, \bar{X}, S^2 分别是样本均值和样本方差, 则

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$. 当 σ 未知, 用 S 代替服从 $t(n-1)$ 分布.

证 $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$, $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 相互独立, 由 t 分布的定义

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} / \sqrt{\frac{(n-1)S^2}{\sigma^2} / (n-1)} \sim t(n-1).$$

由于 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$, 则

$$D\left(\frac{(n-1)S^2}{\sigma^2}\right) = 2(n-1).$$

$D(S^2) = \frac{2\sigma^4}{n-2}$. 随 n 增大, $D(S^2)$ 减小. 样本方差 49/34

定理 5 设 X_1, \dots, X_{n_1} 与 Y_1, \dots, Y_{n_2} 分别是来自正态总体 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的样本, 且相互独立, $((X_1, \dots, X_{n_1})(Y_1, \dots, Y_{n_2}))$. 设 $\bar{X} = \frac{1}{n_1} \sum X_i$,

$$\bar{Y} = \frac{1}{n_2} \sum Y_i,$$

$$S_1^2 = \frac{1}{n_1-1} \sum (X_i - \bar{X})^2, S_2^2 = \frac{1}{n_2-1} \sum (Y_i - \bar{Y})^2.$$

则有 1. $\frac{S_1^2/s_1^2}{\sigma_1^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$;

2. 当 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 时,

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2), \text{ 其}$$

$$\text{中 } S_w^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}, S_w = \sqrt{S_w^2}.$$

$$\text{证明: } \chi_1^2 = \frac{(n_1-1)S_1^2}{\sigma_1^2} \sim \chi^2(n_1 - 1),$$