

Lec-17. 数理统计介绍、随机样本、统计量

主讲教师：吴利苏 (wulisu@sdust.edu.cn)

主 页：wulisu.cn

本节课内容

1. 数理统计部分介绍
2. 统计量与常用统计量
3. 三个重要抽样分布

数理统计

- 数理统计是以概率论为基础, 根据试验或观察数据, 来研究随机现象, 对研究对象的客观规律做出合理的估计和判断.

数理统计

- 数理统计是以概率论为基础, 根据试验或观察数据, 来研究随机现象, 对研究对象的客观规律做出合理的估计和判断.
- 数理统计是数据分析的基础, 数据分析是 AI 的基础.

概率论和数理统计

- 在概率论中, 已知随机变量的分布的前提下, 研究它的性质和规律. 例如, 求数字特征 $E(X)$, $D(X)$ 、求随机变量函数的分布 $F(x)$.
- 在数理统计中, 随机变量的分布未知或者部分未知, 通过数据对随机变量作出推断.

数理统计部分内容

Chap-6 常用的统计量和抽样分布

- χ^2 分布、 t 分布、 F 分布.

Chap-7 估计问题

- 点估计：分布函数已知但参数未知，估计未知参数.
 - ★ 矩估计、极大似然估计.
- 区间估计：估计未知参数处在某个区间的可信程度.

Chap-8 假设检验问题

- 分布函数未知，或分布函数只知道形式而参数未知，提出某些假设，进行检验推断.

基本概念

- 总体 试验的全部可能的观察值;

基本概念

- 总体 试验的全部可能的观察值;
- 个体 总体中的每个可能观察值;

基本概念

- 总体 试验的全部可能的观察值;
- 个体 总体中的每个可能观察值;
- 总体的容量 总体中所包含的个体数;

基本概念

- 总体 试验的全部可能的观察值;
- 个体 总体中的每个可能观察值;
- 总体的容量 总体中所包含的个体数;
- 有限总体 容量有限的总体;

基本概念

- 总体 试验的全部可能的观察值;
- 个体 总体中的每个可能观察值;
- 总体的容量 总体中所包含的个体数;
- 有限总体 容量有限的总体;
- 无限总体 容量无限的总体, 通常将容量非常大的有限总体也按无限总体处理.

例

- 研究 2000 名学生的年龄, 这些学生的年龄的全体构成一个总体, 每个学生的年龄就是个体.
- 一湖泊中某种鱼的含汞量, 有限总体.
- 一城市空气质量, PM2.5 值, 无限总体.
- 考察全国正在使用的某种型号灯泡的寿命所形成的总体. 由于可能观察值的个数很多, 可认为是无限总体.

总体分布

- 总体 X 中的每一个个体有一个的取值, 这些取值构成一个分布, 因此总体 X 可以看成是一个随机变量.
- 总体 X 的分布函数记为 $F(x)$, 称总体 X 具有分布 $F(x)$.

如何推断总体分布的未知参数（或分布）？

在实际中，往往**总体的分布未知**或**总体的分布已知**，**但某些参数未知**。因此要对总体进行推断，研究所有个体是不可能的，故须抽出部分个体进行研究。

如何推断总体分布的未知参数（或分布）？

在实际中，往往总体的分布未知或总体的分布已知，但某些参数未知。因此要对总体进行推断，研究所有个体是不可能的，故须抽出部分个体进行研究。

- 样本 从总体中抽出的部分个体。

如何推断总体分布的未知参数（或分布）？

在实际中，往往总体的分布未知或总体的分布已知，但某些参数未知。因此要对总体进行推断，研究所有个体是不可能的，故须抽出部分个体进行研究。

- 样本 从总体中抽出的部分个体。
- 样本容量 样本中所含个体的个数。

如何推断总体分布的未知参数（或分布）？

在实际中，往往总体的分布未知或总体的分布已知，但某些参数未知。因此要对总体进行推断，研究所有个体是不可能的，故须抽出部分个体进行研究。

- 样本 从总体中抽出的部分个体。
- 样本容量 样本中所含个体的个数。
- 简单随机样本 独立同分布的样本

$(X_1, \dots, X_n)$ 称为容量为 n 的简单随机样本，简称样本。

如何推断总体分布的未知参数（或分布）？

在实际中，往往**总体的分布未知**或**总体的分布已知**，**但某些参数未知**. 因此要对总体进行推断，研究所有个体是不可能的，故须抽出部分个体进行研究.

- **样本** 从总体中抽出的部分个体.
- **样本容量** 样本中所含个体的个数.
- **简单随机样本** **独立同分布**的样本
 $(X_1, \dots, X_n)$ 称为容量为 n 的简单随机样本，
简称**样本**.
- **样本值** $(X_1, \dots, X_n)$ 的观察值 $(x_1, \dots, x_n)$.

如何推断总体分布的未知参数（或分布）？

在实际中，往往**总体的分布未知**或**总体的分布已知**，**但某些参数未知**。因此要对总体进行推断，研究所有个体是不可能的，故须抽出部分个体进行研究。

- **样本** 从总体中抽出的部分个体。
- **样本容量** 样本中所含个体的个数。

- **简单随机样本** **独立同分布**的样本

$(X_1, \dots, X_n)$ 称为容量为 n 的简单随机样本，简称**样本**。

- **样本值** $(X_1, \dots, X_n)$ 的观察值 $(x_1, \dots, x_n)$ 。

注：后面所有的样本均指简单随机样本。

抽样

- 获得简单随机样本的抽样称为(简单随机) 抽样.

抽样

- 获得简单随机样本的抽样称为(简单随机) 抽样.

如何进行抽样?

抽样

- 获得简单随机样本的抽样称为(简单随机) 抽样.

如何进行抽样?

- 对于有限总体, 采用放回抽样.

抽样

- 获得简单随机样本的抽样称为(简单随机) 抽样.

如何进行抽样?

- 对于有限总体, 采用放回抽样.
- 对于无限总体, 一般采取不放回抽样.

抽样

- 获得简单随机样本的抽样称为(简单随机) 抽样.

如何进行抽样?

- 对于有限总体, 采用放回抽样.
- 对于无限总体, 一般采取不放回抽样.
- 但当总体容量很大的时候, 不放回抽样对结果影响较小, 因此通常采用不放回抽样, 并将所得到的样本近似当作 (简单随机) 样本来处理.

样本的分布函数和概率密度函数

若 $(X_1, \dots, X_n)$ 是总体 X 的样本, X 的分布函数为 $F(x)$, 概率密度为 $f(x)$. 由于独立同分布, 故 $(X_1, \dots, X_n)$ 的联合分布函数

$$F^*(x_1, \dots, x_n) = \prod F(x_i)$$

$(X_1, \dots, X_n)$ 的联合概率密度为

$$f^*(x_1, \dots, x_n) = \prod f(x_i).$$

例

设一批灯泡的寿命 X (小时) 服从参数为 θ 的指数分布, θ 未知. 从该批灯泡中采用简单随机抽样抽取容量为 10 的样本 $X_1, \dots, X_{10}$. 对样本实施观测, 得到样本值为

6394	1105	4717	1399	7952
17424	3275	21639	2360	2896

写出样本的概率密度.

解：总体 $X \sim \text{Exp}(\theta)$, $X_1, \dots, X_{10}$ 为来自总体 X 的一个样本, 则 $(X_1, \dots, X_{10})$ 的联合概率密度为

$$\begin{aligned} f^*(x_1, \dots, x_{10}) &= \prod_{i=1}^{10} f(x_i) \\ &= \begin{cases} \frac{1}{\theta^{10}} e^{-\frac{1}{\theta}(x_1 + \dots + x_{10})} & x_1 > 0, \dots, x_n > 0; \\ 0 & \text{其他.} \end{cases} \end{aligned}$$

□

解：总体 $X \sim \text{Exp}(\theta)$, $X_1, \dots, X_{10}$ 为来自总体 X 的一个样本, 则 $(X_1, \dots, X_{10})$ 的联合概率密度为

$$\begin{aligned} f^*(x_1, \dots, x_{10}) &= \prod_{i=1}^{10} f(x_i) \\ &= \begin{cases} \frac{1}{\theta^{10}} e^{-\frac{1}{\theta}(x_1 + \dots + x_{10})} & x_1 > 0, \dots, x_n > 0; \\ 0 & \text{其他.} \end{cases} \end{aligned}$$

□

- 如何由已知样本值来估计未知参数 θ ?

为了估计指数分布的参数 θ , 进行抽样观测, 得到样本 $X_1, \dots, X_{10}$ 的样本值

6394	1105	4717	1399	7952
17424	3275	21639	2360	2896

由 $E(X) = \theta$, 所以可以用样本的均值

$$\bar{X} = \frac{1}{10} \sum_{k=1}^{10} x_i$$

估计未知参数 θ .

构造统计量

从样本中提取有用的信息来研究总体的分布及各种数字特征——构造统计量.

- **统计量** 设 $X_1, \dots, X_n$ 是来自总体 X 的一个样本, $g(X_1, \dots, X_n)$ 是 $X_1, \dots, X_n$ 的函数, 若 g 中不含未知数, 则称 $g(X_1, \dots, X_n)$ 是一个统计量.

构造统计量

从样本中提取有用的信息来研究总体的分布及各种数字特征——构造统计量.

- **统计量** 设 $X_1, \dots, X_n$ 是来自总体 X 的一个样本, $g(X_1, \dots, X_n)$ 是 $X_1, \dots, X_n$ 的函数, 若 g 中不含未知数, 则称 $g(X_1, \dots, X_n)$ 是一个统计量.

- (1) $X_1, \dots, X_n$ 是随机变量, 而统计量 $g(X_1, \dots, X_n)$ 是随机变量的函数.

构造统计量

从样本中提取有用的信息来研究总体的分布及各种数字特征——构造统计量.

- **统计量** 设 $X_1, \dots, X_n$ 是来自总体 X 的一个样本, $g(X_1, \dots, X_n)$ 是 $X_1, \dots, X_n$ 的函数, 若 g 中不含未知数, 则称 $g(X_1, \dots, X_n)$ 是一个统计量.

- (1) $X_1, \dots, X_n$ 是随机变量, 而统计量 $g(X_1, \dots, X_n)$ 是随机变量的函数.
- (2) 设 $x_1, \dots, x_n$ 是相应于样本 $X_1, \dots, X_n$ 的一个样本值, 则称 $g(x_1, \dots, x_n)$ 是 $g(X_1, \dots, X_n)$ 的观察值.

例

设 X_1, X_2, X_3 是来自总体 $N(\mu, \sigma^2)$ 的一个样本, 其中 μ 已知, σ^2 未知, 判断下列各式哪些是统计量.

$$T_1 = X_1,$$

$$T_2 = X_1 + X_2 e^{X_3}$$

$$T_3 = \frac{1}{3}(X_1 + X_2 + X_3), \quad T_4 = \max\{X_1, X_2, X_3\}$$

$$T_5 = X_1 + X_2 - 2\mu, \quad T_6 = \frac{1}{\sigma^2}(X_1^2 + X_2^2 + X_3^2)$$

★常用的统计量★

设 $X_1, \dots, X_n$ 是来自总体的一个样本,,

- 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$;
- 样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right);$$

样本标准差

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

★常用的统计量★

- 样本 k 阶 (原点) 矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, k = 1, 2, \dots;$
- 样本 k 阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k.$

注:

(1) $A_1 = \bar{X}.$

(2) $B_2 \neq S^2.$ 样本方差 S^2 中, 除 n 会低估方差, 为保证无偏性, 故修正为除 $n - 1.$ (Chap7-3)

(3) 矩 $\mu_k = E(X^k),$ 中心矩 $\nu_k = E(X - E(X))^k.$

$\bar{X}, S^2$ 的期望和方差

例

已知 $X_1, X_2, \dots, X_n$ 为总体 X 的样本, $E(X) = \mu$, $D(X) = \sigma^2$. 求 $E(\bar{X}), D(\bar{X}), E(S^2), E(B_2)$.

例

对于正态总体, $D(S^2) = \frac{2\sigma^4}{n-1}$ (下节课).

对于一般总体, 尝试证明

$$D(S^2) = \frac{\nu_4}{n} - \frac{(n-3)}{n(n-1)}\sigma^4$$

其中 $\nu_4 = E((X - E(X))^4)$, $D(X) = \sigma^2$.

<https://zhuanlan.zhihu.com/p/268376613>

<https://math.stackexchange.com/questions/72975/variance-of-sample-variance>

$\bar{X}, S^2$ 的期望和方差

已知对于正态总体 X , $D(S^2) = \frac{2\sigma^4}{n-1}$.

例

已知总体 X 的样本 $X_1, \dots, X_{n_1}$ 和总体 Y 的样本 $Y_1, \dots, Y_{n_2}$ 相互独立, 且 $D(X) = D(Y) = \sigma^2$, 令

$$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2},$$

其中 S_1^2, S_2^2 分别两样本的样本方差. 求 $E(S_w^2), D(S_w^2)$.

总体的参数未知: 样本矩 $\xrightarrow{\text{估计}}$ 总体矩

- 用样本均值 $\bar{X}$ 估计总体均值 $\mu = E(X)$;

总体的参数未知: 样本矩 $\xrightarrow{\text{估计}}$ 总体矩

- 用样本均值 $\bar{X}$ 估计总体均值 $\mu = E(X)$;
- 用样本方差 S^2 估计总体方差 $\sigma^2 = E(X - \mu)^2$;

总体的参数未知: 样本矩 $\xrightarrow{\text{估计}}$ 总体矩

- 用样本均值 $\bar{X}$ 估计总体均值 $\mu = E(X)$;
- 用样本方差 S^2 估计总体方差 $\sigma^2 = E(X - \mu)^2$;
- 用样本矩 A_k 估计总体原点矩 $\mu_k = E(X^k)$;

总体的参数未知: 样本矩 $\xrightarrow{\text{估计}}$ 总体矩

- 用样本均值 $\bar{X}$ 估计总体均值 $\mu = E(X)$;
- 用样本方差 S^2 估计总体方差 $\sigma^2 = E(X - \mu)^2$;
- 用样本矩 A_k 估计总体原点矩 $\mu_k = E(X^k)$;
- 用样本中心矩 B_k 估计总体中心矩 $\nu_k = E(X - \mu)^k$.

总体的参数未知: 样本矩 $\xrightarrow{\text{估计}}$ 总体矩

- 用样本均值 $\bar{X}$ 估计总体均值 $\mu = E(X)$;
- 用样本方差 S^2 估计总体方差 $\sigma^2 = E(X - \mu)^2$;
- 用样本矩 A_k 估计总体原点矩 $\mu_k = E(X^k)$;
- 用样本中心矩 B_k 估计总体中心矩 $\nu_k = E(X - \mu)^k$.

总体的参数未知: 样本矩 $\xrightarrow{\text{估计}}$ 总体矩

- 用样本均值 $\bar{X}$ 估计总体均值 $\mu = E(X)$;
- 用样本方差 S^2 估计总体方差 $\sigma^2 = E(X - \mu)^2$;
- 用样本矩 A_k 估计总体原点矩 $\mu_k = E(X^k)$;
- 用样本中心矩 B_k 估计总体中心矩 $\nu_k = E(X - \mu)^k$.

这些非常直观的想法, 有什么理论依据吗?

总体的参数未知: 样本矩 $\xrightarrow{\text{估计}}$ 总体矩

- 用样本均值 $\bar{X}$ 估计总体均值 $\mu = E(X)$;
- 用样本方差 S^2 估计总体方差 $\sigma^2 = E(X - \mu)^2$;
- 用样本矩 A_k 估计总体原点矩 $\mu_k = E(X^k)$;
- 用样本中心矩 B_k 估计总体中心矩 $\nu_k = E(X - \mu)^k$.

这些非常直观的想法, 有什么理论依据吗?

- 样本矩 $\xrightarrow{P}$ 总体矩.

性质

若总体 X 的 k 阶矩 $E(X^k) = \mu_k$ 存在, 则 $A_k \xrightarrow{P} \mu_k$.

性质

若总体 X 的 k 阶矩 $E(X^k) = \mu_k$ 存在, 则 $A_k \xrightarrow{P} \mu_k$.

证明: 由于 $X_1, \dots, X_n$ 独立且与 X 同分布,

$$E(X_1^k) = E(X_2^k) = \dots = E(X_n^k) = \mu_k,$$

由大数定律知, $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} E(A_k) = \mu_k$. □

进一步由依概率收敛的性质知

$$g(A_1, \dots, A_k) \xrightarrow{P} g(\mu_1, \dots, \mu_k),$$

其中 g 是连续函数. Chap7 矩估计的理论依据.

总体分布未知: 经验分布函数 $\xrightarrow{\text{推断}}$ 总体分布

定义

设 $x_1, \dots, x_n$ 是来自分布函数 $F(x)$ 的总体 X 的样本观察值. X 的经验分布函数 $F_n(x)$ 定义为

$$F_n(x) = \frac{\#(x_i \leq x)}{n}, \quad -\infty < x < +\infty$$

其中 $\#(x_i \leq x)$ 表示 $x_1, \dots, x_n$ 中小于或等于 x 的个数.

性质

$F_n(x)$ 是一个分布函数.

给定样本观察值 $x_1, \dots, x_n$, $F_n(x)$ 满足分布函数的三个条件:

1. $F_n(x)$ 是 x 的不减函数.

2. $0 \leq F_n(x) \leq 1$, $F(-\infty) = 0$, $F(+\infty) = 1$.

3. $F_n(x)$ 是一个右连续函数.

故 $F_n(x)$ 是一个分布函数.

- 将 $x_1, \dots, x_n$ 按自小到大的次序排序, 重新编号为 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$, 则 $F_n(x) =$
$$\begin{cases} 0 & x < x_{(1)}; \\ \frac{k}{n} & x_{(k)} \leq x < x_{(k+1)}, \quad k = 1, 2, \dots, n-1; \\ 1 & x \geq x_{(n)}. \end{cases}$$

- 将 $x_1, \dots, x_n$ 按自小到大的次序排序, 重新编号为 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$, 则 $F_n(x) = \begin{cases} 0 & x < x_{(1)}; \\ \frac{k}{n} & x_{(k)} \leq x < x_{(k+1)}, \quad k = 1, 2, \dots, n-1; \\ 1 & x \geq x_{(n)}. \end{cases}$
- 当 $x_1, \dots, x_n$ 各不同时, $F_n(x)$ 是以等概率 $\frac{1}{n}$ 取 $x_1, \dots, x_n$ 的离散型随机变量的分布函数.

例

设 X 有样本观察值 $-1, 1, 2$, 则

$$F_3(x) = \begin{cases} 0 & x < -1; \\ \frac{1}{3} & -1 \leq x < 1; \\ \frac{2}{3} & 1 \leq x < 2; \\ 1 & x \geq 2. \end{cases}$$

定理 (格里汶科定理)

设 $X_1, \dots, X_n$ 是来自以 $F(x)$ 为分布函数的总体 X 的样本, $F_n(x)$ 是经验分布函数, 则有

$$P \left\{ \lim_{n \rightarrow \infty} \sup_{-\infty < x < \infty} |F_n(x) - F(x)| = 0 \right\} = 1.$$

上面定理表明 $F_n(x)$ 在整个实数轴上以概率 1 均匀收敛于 $F(x)$. 所以, 当 n 很大时, $F_n(x)$ 可以很好地近似总体分布函数 $F(x)$. 这是以样本推断总体的依据.

抽样分布

- 统计量的分布被称为抽样分布.

抽样分布

- 统计量的分布被称为抽样分布.
- 当总体 X 服从一般分布 (如指数分布、均匀分布等), 要得出统计量 (n 个随机变量的函数) 的分布是很困难的.

抽样分布

- 统计量的分布被称为**抽样分布**.
- 当总体 X 服从一般分布 (如指数分布、均匀分布等), 要得出统计量 (n 个随机变量的函数) 的分布是很困难的.
- 当总体 X 服从正态分布时, 统计量 $\bar{X}, S^2$ 的分布是可以计算的, 那么服从什么分布呢?

抽样分布

- 统计量的分布被称为 **抽样分布**.
- 当总体 X 服从一般分布 (如指数分布、均匀分布等), 要得出统计量 (n 个随机变量的函数) 的分布是很困难的.
- 当总体 X 服从正态分布时, 统计量 $\bar{X}, S^2$ 的分布是可以计算的, 那么服从什么分布呢?
- **下节课将介绍数理统计中三个重要的抽样分布:**
 χ^2 分布, t 分布, F 分布.